

A 股量化交易系统

完整工作流文档

文档日期：2026-05-20

项目	A股LightGBM三分类量化选股系统
技术栈	Python 3.11 · LightGBM · Ridge · Pandas · akshare · reportlab
数据来源	通达信本地日线（5644只A股）· 北向资金 · 东方财富 · 同花顺THS
预测目标	未来5日截面三分类（涨/震荡/跌），持仓Top-50，5日调仓
模型IC	测试集 0.020（M3框架无退步，新因子待数据采集后提升）

1. 系统架构总览

系统分为四个阶段：数据采集 → 特征工程 → 模型训练 → 回测与扫描。各阶段通过 Parquet 文件解耦，支持按需独立运行或全量重建。

层次	模块	输入 → 输出
数据采集	TDXCollector / NorthboundCollector FundamentalsCollector / FundFlowCollector ReportCollector / SignalCollector	TDX .day 文件 / akshare API → data/raw/*.parquet
特征工程	assembler.py indicators.py / report.py / signal.py label.py / preprocessing.py	data/raw/ → data/processed/ market_features.parquet (647万行×107列)
模型训练	trainer.py (LightGBM + Ridge 集成) evaluator.py	market_features.parquet → data/models/lgbm_model.txt 等
回测/扫描	backtest/engine.py backtest/metrics.py	data/models/ + data/processed/ → data/backtest/report.html

目录结构

data/		
raw/		
kline/{code}.parquet	←	TDX K5644
northbound.parquet	←	2672
lhb/YYYY-MM-DD.parquet	←	M3
reports/{code}.parquet	←	M3
eps/{code}.parquet	←	EPS M3
fundamentals/{code}.parquet		
fund_flow/{code}.parquet		
processed/		
market_features.parquet	←	
{code}.parquet	←	
models/	←	lgbm/ridge/weights
backtest/	←	+ CSV
watermark.json	←	

2. Phase 0 : 数据准备 (一次性建库)

2.1 同步通达信 K 线

从通达信导出当日快照压缩包，解压并核验文件名日期与实际最大交易日一致后写入水位文件。

```
# ■■■■■■■■■■■■■■■■■■■■■■hsjday-YYYY-MM-DD.zip■  
python main.py sync --zip /path/to/hsjday-2026-05-18.zip  
  
# ■■ TDX .day ■■ → data/raw/kline/*.parquet  
python main.py collect  
  
# ■■■■■■■■■■■■■■■■■■■■■■ PE/PB ■■  
python main.py collect --with-tencent
```

2.2 拉取补充数据

数据类型	命令	耗时	输出路径
基本面（PE/PB/市值）	python main.py fetch-fund	1-2 小时	data/fundamentals/
个股主力资金流向	python main.py fetch-flow	40-60 分钟	data/fund_flow/
北向资金（自动）	collect 步骤已包含	< 1 分钟	data/raw/northbound.parquet
龙虎榜历史（M3）	SignalCollector.fetch_all()	按日数量	data/raw/lhb/
研报数量（M3）	ReportCollector mode=report	约 2 小时	data/raw/reports/
EPS预测（M3）	ReportCollector mode=eps	约 2 小时	data/raw/eps/

M3 新增因子（龙虎榜/研报/EPS）在采集前全部为 NaN，模型仍可运行但无增量信号。

3. Phase 1：特征工程

```
python main.py 1 # ████████~20████5644████
python main.py 1 --sample 100 # ████████████████100█
```

3.1 assembler.py 流程

每只股票独立计算，结果缓存至 data/processed/{code}.parquet，重跑时自动跳过（use_cache=True）。全市场合并后执行截面标签和因子预处理。

步骤	函数	说明
① 读K线	_merge_fundamentals() _merge_fund_flow()	合并基本面、资金流向到K线DataFrame
② 技术因子	add_all_features()	58个技术指标，见3.2节
③ 研报因子	add_report_features()	report_count_30d, analyst_count, eps_consensus_cur, eps_revision
④ 信号因子	add_signal_features()	lhb_net_buy_30d, lhb_count_30d, north_net_5d, north_net_trend
⑤ 截面标签	label.py	截面前30%=涨(2), 后30%=跌(0), 中间=震荡(1)
⑥ 预处理	preprocessing.py	MAD去极值($\pm 5\sigma$) → 截面中性化 → NaN均值填充

3.2 技术因子清单 (indicators.py)

分类	因子列
均线	ma5/10/20/60_ratio (收盘价偏离均线比例)
EMA	ema12, ema26 (中间量，供MACD使用)
MACD	macd_dif, macd_dea, macd_hist, macd_cross, macd_positive, macd_hist_slope
RSI	rsi, rsi_oversold (<30), rsi_overbought (>70)
KDJ	kdj_k, kdj_d, kdj_j, kdj_cross (+2金叉/-2死叉)
布林带	boll_width (带宽), boll_pct (位置百分比), boll_breakout (上轨突破)
ATR	atr (真实波幅), atr_ratio (相对价格)
量能	vol_ratio (量比), vol_trend (短期量趋势)
多周期收益	ret1/3/5/10/20/60/120 (1~120日收益率)
波动率	volatility5, volatility20 (滚动收益率标准差)
价格结构	high_low_ratio, open_close_ratio, upper_shadow, lower_shadow, amplitude_ma5, log_price
衍生动量	momentum_quality (ret20/volatility20), reversal (-ret3)

分类	因子列
量能情绪	price_vol_agree (价量配合), up_streak (连涨天数 ≤ 10)
均线形态	bull_score (多头排列0~3分)
目标	future_ret (未来5日收益), label (截面三分类, 流水线填充)

3.3 M3 新增因子 (report.py + signal.py)

因子	计算逻辑	防前视机制
report_count_30d	30交易日内该股研报数量 (滚动窗口)	available_date = publish_date + 1日历天
analyst_count	30交易日内覆盖分析师数 (研报去重)	同上
eps_consensus_cur	最新EPS一致预期 (向前填充)	merge_asof(direction=backward)
eps_revision	EPS预期变化方向 (+1上调/-1下调/0不变)	drop_duplicates保证唯一快照
lhb_net_buy_30d	30交易日内龙虎榜净买入额累计	available_date = lhb_date + 1日历天
lhb_count_30d	30交易日内龙虎榜上榜次数	同上, pd.bdate_range确保交易日窗口
north_net_5d	北向资金近5日滚动累计净流入	(迁移自indicators.py, 逻辑不变)
north_net_trend	北向资金5日/20日均值比	(迁移自indicators.py, 逻辑不变)

4. Phase 2：模型训练

```
python main.py 2 # 70/15/15
python main.py 2 --rolling # 2
python main.py 2 --walk-forward # WF-CV + 
python main.py 2 --rolling --final #
```

4.1 时序切分（滚动窗口）

滚动窗口模式使用最近2年（504交易日）训练，避免远期数据噪音影响近期预测。

分割	日期范围	样本量	用途
训练集	2022-08-29 ~ 2024-09-25	约 262 万行	LightGBM + Ridge 拟合
验证集	2024-09-26 ~ 2025-07-17	约 104 万行	Early Stopping + 集成权重优化
测试集	2025-07-18 ~ 2026-05-11	约 100 万行	泛化能力评估（不参与训练）

4.2 模型架构

双模型集成：LightGBM 提供分类概率，Ridge 提供连续预测，加权后作为最终信号。

组件	输入	输出	说明
LightGBM	技术/基本面/信号因子	P(跌)/P(震)/P(涨)	三分类，Early Stopping（验证集logloss）
Ridge回归	相同因子集	连续收益预测	辅助信号，压制lgbm极端预测
集成	lgbm_prob_up + ridge_p	最终信号值	$signal = w_lgbm \times P(涨) + w_ridge \times 预测$

4.3 IC 验收结果（M3）

分割	IC	准确率	加权F1
训练集	0.1240	39.1%	0.362
验证集	0.0807	37.8%	0.349
测试集	0.0197	38.5%	0.360

测试集 IC 0.0197 = 基准 0.0197（M3框架无退步）。北向因子已正常填充（66.7%覆盖）；龙虎榜/研报/EPS 因子待采集数据后预期进一步提升 IC。

5. Phase 3 : 回测

```
python main.py 3 # Top-50 5
python main.py 3 --top-k 30 --rebalance 10 # 
python main.py 3 --replace-only # 
```

5.1 回测参数

参数	默认值	说明
持仓数 --top-k	50	每期持仓最多N只（候选池1.5×N）
调仓间隔 --rebalance	5 天	每5个交易日调仓一次
单股权重 --max-weight	5%	单只股票最大仓位
板块权重 --max-sector-weight	40%	单板块最大仓位（分散风险）
换手约束 --max-turnover	50%	单次单向换手率上限
手续费	万3（双向）	买卖各万3
印花税	千1（卖方）	仅卖出收取
滑点	0.2%	双向合计
基准	沪深300	等权重对比

5.2 股票过滤规则

规则	说明
排除ST/*ST	使用akshare实时名称列表，每7天刷新缓存
排除科创板	688xxx前缀，需单独开通权限
排除新股	上市不足250交易日（约1年）
信号过滤	--min-signal 参数，低于阈值不纳入选股池（默认0.0不过滤）

6. 每日增量更新

日常使用无需重跑全量 Phase 1，通过 watermark.json 水位机制只处理新增交易日数据。

```
# ██████████2-3 ████  
python main.py update  
  
# ██████████ PE/PB ████  
python main.py update --with-tencent  
  
# ██████████ Phase 2 ████  
python main.py update --retrain
```

增量更新步骤

步骤	操作	水位更新
① K线增量	mootdx TCP 拉取新K线，追加至 data/raw/kline/	watermark.kline
② 北向快照	NorthboundCollector 追加今日北向数据	watermark.northbound
③ 腾讯快照	TencentCollector (--with-tencent 时)	watermark.tencent
④ 增量特征	assemble_incremental()，只计算 since 水位后的新行	watermark.features
⑤ 重训（可选）	retrain 触发 run_training_rolling()	—

月初全量刷新（月度通达信数据包）：

```
python main.py sync --zip hsjday-YYYY-MM-DD.zip # ██████  
python main.py 1 # ████████  
python main.py 2 --rolling # ████
```


7. 选股扫描 (scan)

快捷指令，读取最新截面推断特征并输出当日 Top-N 候选股排名，供盘后决策参考。

```
python main.py scan # ■■ Top-20■■■■1.5x
python main.py scan --top-k 30 # ■■■■■
```

输出说明

字段	说明
rank	全市场信号强度排名
code	股票代码
segment	板块（主板/中小板/创业板等）
close	最新收盘价
signal	集成信号值（w_lgbm×P(涨) + w_ridge×预测）
signal_pct	全市场分位（1.0=最强）

排名前 Top-K 标注 ◀ 为建仓候选；继续持有条件：仍在前 1.5×Top-K 名内；跌出 1.5×Top-K → 纳入卖出候选（散户模式 --replace-only 进一步降低换手）。

8. 数据采集器 (Collectors)

采集器	数据源	输出	接口
TDXCollector	通达信本地.day文件	data/raw/kline/{code}.parquet	fetch_all() / fetch_incremental_moo tdx()
NorthboundCollector	同花顺THS	data/raw/northbound.parquet	fetch_all([])
FundamentalsCollector	akshare东财	data/fundamentals/{code}.parquet	fetch_all(codes)
FundFlowCollector	akshare东财	data/fund_flow/{code}.parquet	fetch_all(codes)
TencentCollector	腾讯财经	data/raw/tencent/{code}.parquet	fetch_all(codes)
ReportCollector (mode=report)	akshare东财研报	data/raw/reports/{code}.parquet	fetch_all(codes, mode='report')
ReportCollector (mode=eps)	同花顺THS EPS	data/raw/eps/{code}.parquet	fetch_all(codes, mode='eps')
SignalCollector	akshare东财龙虎榜	data/raw/lhb/YYYY-MM-DD.parquet	fetch_all(codes, date=d)

BaseCollector 通用机制

所有采集器继承 BaseCollector，具备以下共同能力：

- 增量跳过 (incremental=True)：检查本地缓存，有效则跳过，返回 stats.cached
- 断路器 (max_errors)：连续失败超阈值后自动终止，避免封禁
- 进度追踪：tqdm 进度条 + CollectStats(ok/fail/cached) 返回
- 延迟控制：请求间默认延迟，可通过 delay 参数调整

9. 常见问题与处理

问题	原因	处理方法
market_features.parquet 行数异常少	调试模式 sample_size 参数遗留， 或 Phase 1 中途中断	python main.py 1 全量重建
测试集 IC 异常低（接近0）	关键因子全为 NaN（如北向因子）	检查 assembler 是否正确调用 add_signal_features；查看日志
north_net_5d 全为 NaN	assembler 重复 merge 导致列名被 pandas 加 _x/_y 后缀	已修复 (ea1d1a8)：删除了 重复的 _merge_northbound 调用
回测末期资产归零	market_features.parquet 因 dropna 导致最后5个交易日数据缺失	保证通达信数据截止日期在 标签计算期之后（+5交易日）
akshare 接口限流/超时	请求频率过高	增大 --delay 参数；断路器 触发后重跑（自动跳过已缓存）
新股/ST误入选股池	ST缓存过期或代码识别失败	ST_CACHE_DAYS=7 自动刷新； 手动执行 get_st_codes(refresh=True)

10. 命令快速参考

命令	场景
python main.py sync --zip <压缩包>	月度：导入通达信数据包
python main.py collect	月度：转换K线 + 北向快照
python main.py fetch-fund	季度：刷新PE/PB/市值基本面
python main.py fetch-flow	季度：刷新主力资金流向
python main.py 1	月度：全量重建特征（~20分钟）
python main.py 2 --rolling	月度：滚动窗口重训模型
python main.py 3	按需：回测评估
python main.py update	每日：增量更新K线+特征
python main.py update --retrain	每日：更新+重训
python main.py scan	每日收盘：输出选股信号
python main.py 1 --sample 50	调试：仅处理50只股票
python main.py 2 --walk-forward	诊断：WF-CV验证模型稳定性